Expectimax 探索結果から Policy と Value を学習する 2048 向け AlphaZero 型強化学習

Learning Policy and Value from Expectimax Search for AlphaZero-Style Reinforcement Learning in 2048

金子　智弥　　松崎　公紀　　（高知工科大学）

1　はじめに

AlphaZero では，モンテカルロ木探索（MCTS）の探索結果と自己対戦結果を，Policy と Value を出力するネットワークへ学習させる [1]．2048 には確率遷移を学習する Stochastic MuZero が適用されているが，学習時の各着手で 100 回の MCTS simulation を行う大規模な計算を要する [2]．また，Monte-Carlo Softmax 探索の内部値を学習に用いた先行研究では，過大評価による Value の発散が報告されている [3]．

本研究は，完全解析された確率的一人ゲーム「ミニ 2048」[4] を対象とする．完全解析値から各局面の最善手集合と各手の期待得点が得られるため，平均得点に加え，選択手の正しさと損失を進行度別に評価できる．本研究では，MCTS の反復 simulation を深さ 2 の Expectimax 探索に置き換える．深さ 2 の Expectimax は，確率遷移を直接平均して評価し，着手ごとに simulation を反復しないため，100 回の MCTS simulation を用いる場合より学習時の探索計算を大幅に抑えられる．この探索から Policy の目標手と afterstate Value の目標値を同時に生成し，両 CNN へ学習させる 2048 向け AlphaZero 型強化学習を提案する．次局面の最良手を用いる最大値方式，Policy の選択確率で平均する Expectiavg 方式，および一手後を Value 自身で評価する TD 方式を比較し，学習した Policy と Value を併用する効果を調べる．

2　探索に基づく Policy–Value 学習

ミニ 2048 の player state を S_t，行動 A_t の slide･merge 直後かつ新タイル生成前の afterstate を S'_t，即時報酬を r_t とする．1 手の遷移は

$$S_t \xrightarrow{A_t, r_t} S'_t \xrightarrow{\text{chance}} S_{t+1}$$

である．chance node では，空き位置を一様に選び，値 2 と 4 をそれぞれ確率 0.9，0.1 で生成する全結果を列挙する．Value CNN は afterstate S'_t を入力とし，S'_t を生成した際の報酬 r_t を含まない将来得点を出力する．Policy CNN は player state S_t から 4 方向の logit を出力し，非合法手を除いて softmax を計算することで，合法手の選択確率 π を得る．

深さ 1 の行動価値と Policy の選択確率を

$$v_{d=1}(S,a) = r(S,a) + V(S'(a)), \qquad p(S,a) = \pi(a \mid S) \tag{1}$$

とする．深さ 2 の探索では，S'_t から生成される各 S_{t+1} の先を，最大値方式と Policy 加重平均方式でそれぞれ

$$B_{\max}(S'_t) = \mathrm{E}_{S_{t+1}|S'_t}\left[\max_a v_{d=1}(S_{t+1}, a)\right], \tag{2}$$

$$B_{\pi}(S'_t) = \mathrm{E}_{S_{t+1}|S'_t}\left[\sum_a p(S_{t+1}, a) v_{d=1}(S_{t+1}, a)\right]. \tag{3}$$

B_π は，chance node のタイル生成確率と次の player node の Policy 確率を用いる二重の平均であり，本稿では Expectiavg と呼ぶ．複数の合法手を反映するため，単一の最大予測値を選ぶ $B_{\max}$ より，過大評価された一つの葉の影響を抑える狙いがある．合法手のない S_{t+1} の継続価値は 0 とし，MCTS の訪問回数や探索項は用いない．

一手前の afterstate S'_{t-1} に対する Value 学習目標を，$r_t + B_{\max}(S'_t)$（$\mathrm{V}_{\max}$），$r_t + B_\pi(S'_t)$（V_π），$r_t + V(S'_t)$（V_{no}）とする．V_{no} だけは深さ 2 探索値を使わない 1-step TD 方式である．Policy 学習目標 $\mathrm{P}_{\max}$，P_π は，それぞれ $r + B_{\max}$，$r + B_\pi$ を最大化する手とする．すなわち，Policy CNN には探索が選んだ手を，Value CNN には探索が見積もった将来得点を学習させる．

評価時は同じ backup を再帰した深さ d の行動価値を $v_d(S,a)$ とし，$v_d(S,a)$，$p(S,a)$，または $p(S,a)v_d(S,a)$ を最大化する．以下では各方式を v_d，p，$p \times v_d$ と記す．d は player move 基準の探索深さであり，p は探索を行わない．

3　実験条件

Value 学習目標 3 方式と Policy 学習目標 2 方式の 6 条件を，学習時の行動選択を $v_{d=1}$ に固定して比較する．これに，Policy を持たず，V_{no} で Value のみを学習し，$v_{d=1}$ で行動を選ぶ TD-Afterstate baseline を加えた．baseline は Policy 学習と深さ 2 の探索を行わない．学習時に $p \times v_{d=1}$ で行動を選ぶ product 条件も同じ 6 通り実施したが，性能向上が見られず，紙面の都合から結果は省略する．盤面は指数表現の 3×3，CNN 入力は空きを含む 11 チャネル one-hot 表現である．training seed は 1 とし，256 並列局を 1 手ずつ進めるベクトル化 ply を 250,000 回実行した．各サンプルを 8 対称に展開し，batch size 128，学習率 10^{-4} で学習した最終 checkpoint を seed 101 の 2,000 ゲームで評価した．

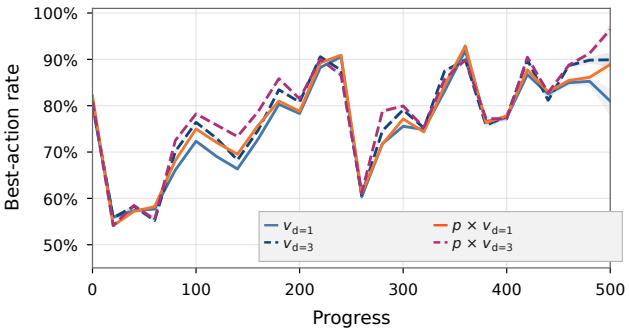


図 1　V_π–P_π の進行度別最善手率（seed 101，各 2,000 ゲーム；進行度=盤上タイル値総和/2，0–500）．各曲線は各方式の訪問局面で集計した．

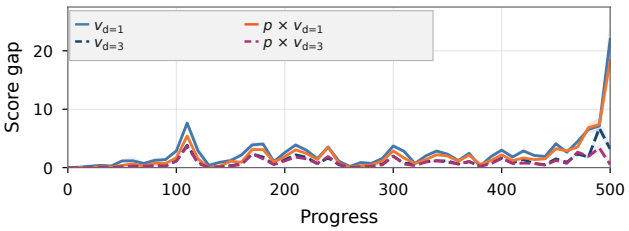


図 2　V_π–P_π の進行度別期待得点差（最善手と選択手の差；0 が最善）．評価条件は図 1 と同じ．

主要指標を平均得点とした．さらに完全解析値を用い，選択手が最善手集合に含まれる割合（Accuracy，以下「最善手率」）と，最善手との期待得点差を算出した．これらは各手法が自身のプレイ中に訪れた局面上の集計であり，手法間で共通の局面分布ではない．

4　実験結果

6 条件と baseline の平均得点を表 1 に示す．

表 1　学習目標別の平均得点（2,000 ゲーム）

学習条件	$v_{d=1}$	$v_{d=3}$	p	$p \times v_{d=1}$
TD baseline	3,634	4,904	–	–
V_{max}–P_{max}	4,406	5,118	5,134	5,091
V_{max}–P_π	4,574	5,115	5,097	5,197
V_π–P_{max}	4,779	5,154	4,924	5,065
V_π–P_π	4,855	5,169	5,103	**5,228**
V_{no}–P_{max}	4,447	5,011	5,104	5,001
V_{no}–P_π	3,686	4,952	5,013	5,087

v_d では $d = 1$ から 3 への変更により，6 条件の平均得点が 314–1,266 点上昇した．一方，$p \times v_{d=1}$ と $v_{d=3}$ の得点差（前者 − 後者）は −89–+135 点で，6 条件の単純平均はそれぞれ 5,112 点と 5,087 点であった．ただし統計的な同等性は示していない．

図 1 では，進行度 100–500 で深さ 3 の曲線が対応する深さ 1 をおおむね上回る．表示範囲の全訪問局面を手数で重み付けすると，最善手率は $v_{d=1}$ と $v_{d=3}$ で 73.42%，75.36%，$p \times v_{d=1}$ と $p \times v_{d=3}$ で 74.93%，76.52%であった．図 2 の期待得点差は同じ順に 1.95，0.89，1.47，0.78 であり，深さ 3 では最善手率が 1.59–1.94 ポイント高まり，選択手全体の平均期待得点差はどちらの系列でもおよそ半分になった．また，V_{max}–P_π と V_π–P_{max} の最終ログ点では，$B_{max} - B_\pi$ は B_{max} の 1.2–1.9%，P_{max} と P_π の目標手一致率は 87.9–92.6%であった．これは単一 batch における診断値である．

5　考察

表の 6 条件と V_π–P_π の完全解析指標は，調べた CNN と深度では，深い Expectimax が浅い Value 評価を補正したという解釈と整合する．ただし各方式の訪問局面上の観測であり，図 1 でも深さ 3 が全進行度で上回るわけではない．N タプルでは深い探索が最善手から離れる例もある [5]．

Expectiavg に基づく V_π–P_π と $p \times v_{d=1}$ の組合せが最高得点を示し，浅い $p \times v_{d=1}$ の平均が $v_{d=3}$ に近かったことは，探索結果を学習した Policy と Value の併用が有効である可能性を示す．p 単独でも 4,924–5,134 点を得ており，Policy が深さ 2 探索の着手情報を保持したという解釈とも整合する．ただし $p \times v_d$ は Value の原点と符号にも依存するため，得点の近さは深い探索の代替や MCTS の再現を示すものではない．

最大値方式は過大評価された葉を選びやすく，Policy 加重平均方式は未成熟な Policy に左右される．目標手一致率が 87.9–92.6%であったことから，両方式の差は一部の判断に集中している可能性がある．最高値だけでは両方式の優劣を判定できない．また，V_{no}–P_{max} と V_{no}–P_π は Value 目標式と行動選択が同じだが，$v_{d=1}$ は 4,447 点と 3,686 点に分かれた．Policy 同時学習の間接的影響と run 変動は単一 seed では分離できない．今後は複数 seed と共通固定局面集合を用いた比較が必要である．

6　まとめ

MCTS を深さ 2 の Expectimax/Expectiavg へ置き換え，その探索結果から Policy と Value を学習する 2048 向け AlphaZero 型強化学習を提案した．単一 seed では，V_π–P_π を $p \times v_{d=1}$ で評価した条件が最高の 5,228 点を示し，Policy と Value の併用可能性を確認した．ただし方式間の優劣は判断できない．今後は複数 training seed と共通局面集合で検証する．

参考文献

[1] D. Silver et al.: A General Reinforcement Learning Algorithm that Masters Chess, Shogi, and Go through Self-Play, *Science*, Vol.362, No.6419, pp.1140–1144 (2018).

[2] I. Antonoglou, J. Schrittwieser, S. Ozair, T. K. Hubert, and D. Silver: Planning in Stochastic Environments with a Learned Model, *Proc. ICLR* (2022).

[3] 渡邊翔太：ゲーム「2048」への Monte-Carlo Softmax 探索の適用，高知工科大学大学院修士学位論文 (2024).

[4] 山下修平，金子知適，中屋敷太一：3 × 3 盤面の 2048 の完全解析と強化学習の研究，ゲームプログラミングワークショップ 2022 論文集，pp.1–8 (2022).

[5] 寺内俊輔，松崎公紀：ミニ 2048 の完全解析を用いた N タプルネットワーク+Expectimax 探索プレイヤの分析，第 65 回プログラミング・シンポジウム予稿集，pp.83–90 (2024).