ミニ 2048 における Double Q 学習の効果：過大評価を乗り越えるために

The Effect of Double Q Learning in Mini 2048: Resolving Overestimation

金子　智弥　　松崎　公紀　　（高知工科大学）

1　はじめに

近年，深層強化学習について多くの研究があり，様々なアルゴリズムが提案されている．それらアルゴリズムの善し悪しを理解する上で，正確かつ細粒度な評価は重要である．著者らは，完全解析されたゲームにおける期待得点を評価値とするプレイヤを通して，深層強化学習アルゴリズムの理解を目指している．

本研究では，完全解析がされた確率的一人ゲーム「ミニ 2048」[4] を対象とする．ミニ 2048 においては，完全解析により全局面に対して得点の期待値の最大値が分かっており，それらを用いるパーフェクトプレイヤが実現できる．著者らはこれまでに，ミニ 2048 に対する深層強化学習で評価値の過大評価が起こる問題を発見した．本研究では，過大評価が起こる原因を解明するとともに，過大評価を防ぐのに有効とされている Double Q 学習 [1] を適用し，評価実験を行う．

2　既存の問題：対称性の導入による過大評価

ミニ 2048 の各盤面に対し，回転・鏡像により 8 通りの対称盤面が存在する．学習をロバストに行うという観点からは，この対称性を導入した学習が有効だと考えられるが，対称性の導入は過大評価という別の問題を引き起こしてしまう．

以降の実験では，$3 \times 3 \times 11$ の入力に対して，5 層の畳み込み層と 2 層の全結合層からなるネットワークを用いる．最初にサイズ 1×1，チャネル数 64 のカーネルで畳み込みを行う．以降はすべてサイズ 2×2 のカーネルで畳み込みを行い，チャネル数は順に 128，232，256，256 とし，2 層目のみパディング 1 を施す．各畳み込み後に ReLU 活性化関数を適用する．最後に，出力 256，1 の全結合層 2 層を通じてスカラーの評価値を出力する．

このネットワークに対して，TD-Afterstate（タイルをスライドさせた直後の盤面に対する TD 誤差学習）により 24 時間の学習を行う．最適化手法は Adam（学習率 0.001）を用い，バッチサイズは 1024 とする．対称性の有無により，以下の 2 つの学習方法について試す．

TDA　学習エピソードに含まれる各盤面に対し，8 通りの対称盤面を生成しすべて学習する．

TDA-nosym　学習エピソードに含まれる盤面をそのまま学習する．

図 1 は，各プレイヤのプレイで出現した局面（afterstate）を，パーフェクトプレイヤの評価値を横軸（x）に，プレイヤの評価値を縦軸（y）にとった散布図である．TDA-nosym では，点 (初期盤面の期待値, エピソード平均得点) を通る直線上に点が分布している．TDA では，およそ $y = x$ 上に点が分布するものの，$x > 4500$ のゲーム序盤では評価値の過大評価が生じている．

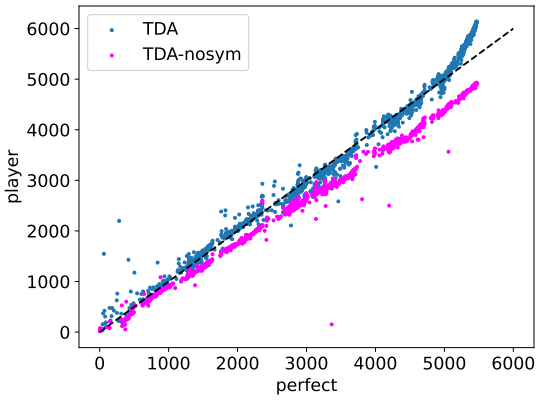


図 1　対称性の有無による評価値の散布図

3　ゲーム序盤での過大評価の理由解明

TD 学習において過大評価に関して，局面の評価値が似た値をとることがその原因の一つだと考えられている．そこで，本研究ではこの仮説のもと，良い手と悪い手の差が小さい局面がどのくらいの頻度で出現するかについて調査した．まず，パーフェクトプレイヤのプレイから 347,732 局面（重複あり）を抜き出した．各局面の最大 4 つの手から最大評価値でグルーピングし（横軸，x），「最小評価値÷最大評価値」を縦軸に箱ひげ図を描画したものが図 2 である．

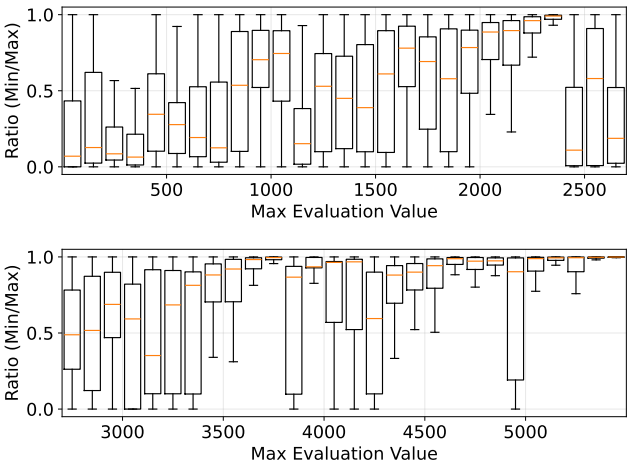


図 2　パーフェクトプレイヤの評価値の最小／最大の比（ただし，外れ値は表示していない）

この図から，ミニ 2048 において，4 つの評価値がとても近い値になるところが 3 箇所見られる．$2300 < x < 2400$ と $3700 < x < 3800$ は，それぞれ 512 タイルと 256 タイルができた直後で，他のマスは空白または小さな値のタイルからなっている．$4600 < x$ はゲーム序盤に対応し，やはり小さな値のタイルかなる局面である．図 1 の TDA の結果と比較すると，過大評価が見られるのはこれらの範囲である．したがって，局面の評価値が似た値をとることが過大評価の原因であり，単純な TD 学習では避けることはできないこととなる．

4 Double Q 学習を用いた実験

単純な TD 学習では過大評価を避けることができないため，本研究では Double Q 学習 [1,2] のアイデアを適用し評価を行う．具体的には次の 3 つのプレイヤを実装した．

D-TDA-X 独立な二つのネットワークを作り，互いのネットワークから学習を行う．学習対象となるネットワークはエピソードごとに切り替える．

D-TDA-C DDQN [2] に倣って，学習を行う主ネットワークと学習データを提供する副ネットワークからなる．主ネットワークの学習 100 バッチごとに，主ネットワークを副ネットワークへコピーする．

D-TDA-CB 主ネットワークと副ネットワーク 2 つからなる．副ネットワークへのコピーは 50 バッチごととし，ダブルバッファで切り替える．したがって，過去 50〜100 バッチで学習した主ネットワークを副ネットワークとして利用する．

学習のパラメータ等は 2 節のそれらと同じであるが，学習速度の低下を想定し 120 時間学習を行った．図 3 に学習の進行状況を，図 4 に学習結果のモデルを用いた評価値の散布図を示す．

学習の進行について，2 つのネットワークを利用することから D-TDA-X は学習が遅いが，最終的には最も良いスコアが得られている．評価値の散布図について，D-TDA-C と D-TDA-CB の 2 手法ではいずれも $x > 4500$ において過大評価が起きている．ミニ 2048 ではタイルの出現はランダムであるが，主・副ネットワークの独立性を得るには不十分だという結果となった．一方，D-TDA-X では，$y = x$ の直線から大きく分布が下がっており，$x > 4500$ ではさらに過小評価が見られる．Double Q 学習において過小評価が起こることは，[3] などでも指摘されている．

5 まとめ

本研究では，ミニ 2048 の深層強化学習において対称性を用いて学習を行った際の過大評価が発生する理由の解明，ならびに，Double Q 学習の適用による効果を実験的に評価した．Double Q 学習を適用した D-TDA-X では過大評価は避けられることが分かったが，評価値が下方にずれることや過小評価の問題が残ることが判明した．

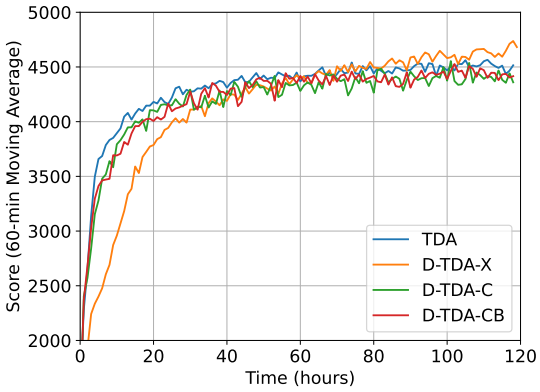


図 3　4 学習手法での学習の進行状況

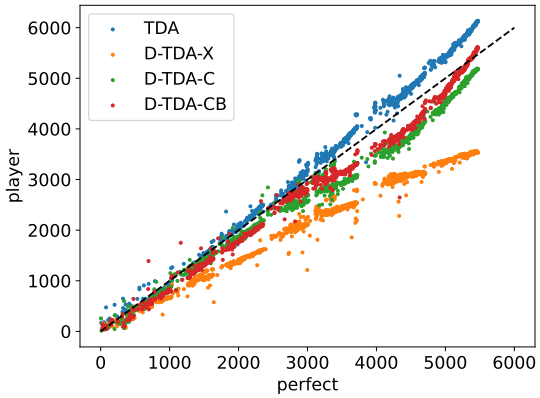


図 4　4 学習手法での評価値の散布図

特に探索を組み合わせる場合において，散布図上で $y = x$ の直線上に評価値が分布することが理想的である．各学習手法で得られた評価値を探索と組み合わせた場合の挙動について，現在実験を実行中である．この結果を含めて，本研究で実装した 4 学習手法の評価を最終論文にまとめる予定である．今後の課題の一つは，過大評価を避けつつ $y = x$ の直線上に評価値が分布するような学習手法を提案することである．

参考文献

[1] H. Hasselt: Double Q-learning. NIPS 2010, 2010.

[2] H. van Hasselt, A. Guez, D. Silver: Deep reinforcement learning with double Q-learning. AAAI'16, 2016.

[3] Z. Ren, G. Zhu, H. Hu, B. Han, J. Chen and C. Zhang: On the estimation bias in double Q-learning. NeurIPS 2021, 2021.

[4] 山下修平, 金子知適, 中屋敷太一: 3 × 3 盤面の 2048 の完全解析と強化学習の研究. GPW-22, 2022.