大貧民におけるグラフニューラルネットワークを用いた評価関数の設計・評価

Design and Evaluation of Evaluation Function Using Graph Neural Network in Daihinmin

福澤 詩音　　松崎 公紀　　(高知工科大学)

1　はじめに

大貧民は日本で広く親しまれているトランプゲームであり，多人数・不完全情報ゲームに分類される．ペアや階段といった役，8 切りや革命による強弱の反転などの独自ルールを持ち，相手の手札や戦略を読みながら自分の手札を効率よく処理する戦略性が求められる．大貧民は，UEC コンピュータ大貧民大会 (UECda) [1] を中心に研究が進められ，探索を用いたプレイヤが長く上位を占めてきた [5]．しかし，探索には高い計算コストや，評価関数設計における人手のコストといった課題が残る．

本研究では，探索を用いないニューラルネットワーク型評価関数を設計し，その有効性を検証する．特に，局面をカードのグラフとして表現するグラフニューラルネットワーク型の評価関数を提案し，局面を画像として捉える畳み込みニューラルネットワーク，および両者の特徴を融合したモデルと比較して評価実験を行う．

2　関連研究

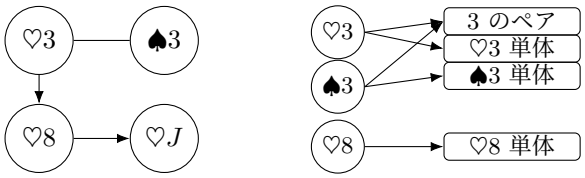
グラフニューラルネットワーク (GNN) は, グラフ構造データを入力し, 隣接ノードの特徴を集約してノードやグラフ全体の表現を学習する．代表的手法の GCN [3] は文献ネットワークのノード分類で高精度を示した．ゲーム研究にも応用され, チェスをノードと指し手のグラフで表現し GNN で評価関数を学習する研究 [2, **?**] があるが, 依然として研究例は少ない．

3　大貧民のグラフ表現

本研究では，各局面を二つのグラフを用いて表現する．一つはカードの並びや強弱の関係を捉えるグラフであり，もう一つはその手札から実際に場へ出せる手を捉えるグラフである．前者でカード同士の関係を学習し，その結果を後者へ受け渡すことで，どのカードがどの手を構成しうるかを一貫して表現する．

一つ目は，ゲームで用いる 53 枚のカードをノードとするグラフである．同じランクのカード同士を辺で結び，ペアや 3 枚出しなどの組を作りうる関係を表す．さらに強さが隣り合うカードを弱い方から強い方へ向かう辺で結び，カードの強弱の順序を表現する．革命によって強弱が反転した場合は，この強さ方向の辺の向きを逆にすることで盤面の変化を反映する．

二つ目は，自身の手札のカードと，そこから構成される候補手とを結ぶ二部グラフである．候補手とは場の状況において提出可能な一つ一つの手であり，各候補手のノードはそれを構成するカードのノードと辺で結ばれる．これにより一つ目のグラフで得たカードの表現を集約して候補手の表現を作り，どのカードの組み合わせがどの手に対応するのかをネットワークへ与える．



(a) カードグラフの例　　(b) 二部グラフの例

図 1　大貧民のグラフ表現の例

4　実験

本研究で比較するモデルは以下の 3 つである．

- GNN：隠れ次元は 128，カード埋め込みは 64 次元とし，同ランク辺・強さ順辺・自己ループの各経路を集約する．
- CNN：盤面を 4×13 の画像として扱う畳み込みネットワークであり，残差ブロック（ResNet 型）を積む．
- 融合：学習済みの GNN と CNN が出力する候補手表現および文脈を連結し，共通の全結合ヘッドで方策と状態価値を出力する．

教師データには UECda コンピュータ大貧民大会に出場したクライアントの指し手を用いた．具体的には Blauweregen と他の出場クライアントである jn17，res.kou2，GAM，switch，Rappa，Ganesa，大会サンプルエージェントを対戦させ，Blauweregen が選択した手を教師データとして抽出した．試合数は 10 万試合，局面数にして 114 万局面であり，学習データと検証データに 8:2 の割合で分割した．

学習は，候補手の中から Blau が選んだ手を当てる教師あり学習で行う．損失は方策の交差エントロピーと状態価値の二乗誤差の和とした．最適化には Adam を用い，学習率は 1×10^{-4} を初期値として設定し，エポック数は 30 とした．

評価は，学習したモデルを 1 体，公開クライアント switch を相手 4 体として 4000 局対戦させ，最終的な得点で比較した．

5　結果

各モデルの switch 4 体との対戦成績を表 1 に示す．

CNN と GNN では明確なスコアの差は見られなかったが，CNN と GNN を融合したモデルでは，CNN や GNN

表 2　各モデルの一致率と価値予測精度

モデル	一致率	非自明一致率	選択確率	価値 MSE
融合	**0.774**	**0.718**	**0.725**	**0.103**
GNN	0.762	0.707	0.690	0.104
CNN	0.762	0.702	0.699	0.119

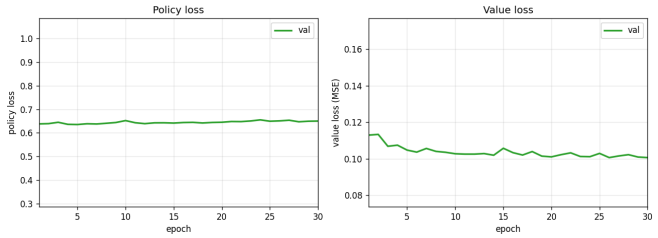


図 2　損失の推移（融合モデル）

単体よりも高いスコアを得ることができた．いずれもモデルも swich を超えるような明確な強さは得られなかった．

図 3 にモデルの損失の推移を示す．文章量の関係上，融合したモデルの損失のみを図で示す．方策のロスは学習の進行に伴い減少する傾向は見られなかった．

表 2 の各列は以下を表す．一致率は，モデルが最も高いスコアを与えた手が教師の選択した手と一致した局面の割合である．非自明一致率は，提出可能な候補手が 3 つ以上存在する局面に限定した一致率であり，パスや提出可能な手が 1 つのみといった選択の余地が小さい局面を除いた，より判断を要する局面での精度を表す．選択確率は，モデルが出力する各手の確率のうち，教師が実際に選択した手へ与えた確率の平均であり，値が大きいほど教師の手を高い確信度で予測していることを示す．価値 MSE は，各局面の価値の予測値と，その局を最後までプレイした際に実際に得られた正規化報酬との平均二乗誤差であり，値が小さいほど盤面の有利不利を正確に予測できていることを示す．

表 1　switch 4 体との対戦成績（4000 局）

モデル	最終スコア	平均得点
GNN	10680	2.67
CNN	10400	2.60
CNN ＋ GNN	**11360**	**2.84**

6　考察

融合が単体および出力平均を上回った要因として，GNN と CNN の相補性が挙げられる．同一局面での両者の選択を比較すると，約 2 割の局面で判断が分かれ，GNN は保守的に札を温存し弱い札を出す傾向を，CNN は強い札を切る攻撃的な傾向を示した．異なる観点で盤面を捉える二つのモデルを特徴レベルで統合することで，一方だけでは得られない判断が可能になったと考えられる．出力の平均によるアンサンブルでは，この統合が学習されないため効果が乏しかった．

一方，いずれのモデルもライト級優勝クライアントには届かなかった．相手情報の追加や学習目的の変更などを試みると検証精度が向上する場合もあったが，対戦性能は一定の水準で頭打ちであった．これは，教師の手を正確に模倣できても，教師が持つ多手先の読みまでは再現できないためと考えられる．すなわち本手法の限界は表現の不足ではなく，模倣と浅い評価に基づく枠組み自体にあり，強豪に迫るには探索の導入が必要であることが示唆される．

負けた対局を分析すると，その多くは配牌が弱く打開が困難な局面であった．一方で，一度優勢になりながら終盤で順位を落とす対局も一定数見られ，多手先の手順を要する終盤の詰めに課題があることが分かった．．本稿では，さらに分析を行う．

7　まとめ

本研究では，大貧民の局面をカード間の関係を表すグラフと，手札と候補手を結ぶ二部グラフの二つで表現し，グラフニューラルネットワークにより方策と状態価値を学習する手法を提案した．GNN，CNN，および両者を結合する融合モデルを比較した結果，融合モデルが一致率と価値予測精度のいずれでも最も高い性能を示した．本稿では，

参考文献

[1] 電気通信大学，“UECda コンピュータ大貧民大会”，https://flute.u-shizuoka-ken.ac.jp/daihinmin/2023/document_rules.html，2026 年 7 月閲覧．

[2] Tomas Rigaux, Hisashi Kashima, “Enhancing Chess Reinforcement Learning with Graph Representation”, 38th Conference on Neural Information Processing Systems NeurIPS 2024.

[3] Thomas N. Kipf, Max Welling, “Semi-Supervised Classification with Graph Convolutional Networks”, Published as a conference paper at ICLR 2017.

[4] Tomas Rigaux, Hisashi Kashima, “Enhancing Chess Reinforcement Learning with Graph Representation”, Published as a conference paper at NeurIPS 2024.

[5] 大渡勝己, 田中哲朗, “方策勾配を用いた教師有り学習によるコンピュータ大貧民の方策関数の学習とモンテカルロシミュレーションへの利用”, 情報処理学会研究報告, 2016.