大貧民における方策・価値評価関数の学習とその利用法

福澤　詩音　　【 高度プログラミング研究室 】

1　はじめに

多人数・不完全情報ゲーム「大貧民」は，手札のランダム性と，プレイヤの多さから，単純なモンテカルロ木探索では有効な手を見つけることが難しい．本研究では，大貧民における方策・価値評価関数を学習し，その情報を用いて有効な手を見つける手法を提案する．また，不完全情報ゲームにおける強化学習の有効性についても検証する．

2　ネットワーク構成

ネットワークは，方策ネットワークと価値評価ネットワークの 2 つから構成される．方策ネットワークは，現在の局面における各手の選択確率を出力する．価値評価ネットワークは，現在の盤面における提出可能な手のそれぞれについて，その手を選択した場合のスコアを予測する．大貧民では，すべての提出手のパターンを列挙することは困難であるため，提出手の表現を簡単にした．具体的には，提出手を,「ランク」・「枚数」・「役」の 3 つで構成し，方策ネットワークの出力とした．ニューラルネットワークへの入力は，以下の要素で構成される [1].

- **場の状態**: 縛り，革命，場のカードのスート
- **手札の情報**: 自分の手札，全プレイヤの既出カード
- **場，提出カード**: 場のカード，提出可能なカード
- **プレイヤ情報**: 全プレイヤの手札枚数，ランク

全プレイヤの使用済みカード，手札枚数，ランクに関して，自分を先頭とした順番に情報を並べる．ネットワークの構成は全層結合で，活性化関数には ReLU を用いる．方策ネットワークの出力層には Softmax 関数を用い，価値評価ネットワークの出力層には活性化関数を用いず，各手のスコア予測値を出力する．最終的なスコアの予測値 S の式は，以下の通りである．

$$S = \alpha v + (1 - \alpha)(r + q + t) \tag{1}$$

ここで，v は価値評価ネットワークからの出力，r，q，t はそれぞれランク，枚数，役の対数確率，α は方策・価値評価の比率を表す．

3　実験

学習は，教師あり学習と強化学習を組み合わせて行う．対戦環境は，UECda コンピュータ大貧民大会のサーバーを用いる [2]．まず，ルールベースプレイヤ 5 体の対戦データを用いて教師あり学習による初期モデルを構築する．次に，初期モデルを用いて対戦を行い，強化学習によってモデルを強化する．教師あり学習は，ルールベースプレイヤ 5 体の 100000 試合分の対戦データを用いて行う．強化学習は，ルールベースプレイヤ 2 体，初期モデル 2 体，強化学習クライアント 1 体を用いて 600000 試合の対戦を行う．局面数は，教師あり学習は約 300 万局面，強化学習は約 600 万局面である．提出手の選択は，方策ネットワークと，価値評価ネットワークから出力された値の合計比率が 1 になるようにした値を用いる．図 1 は，方策と価値評価の比率をそれぞれ変化させたものに対して，ルールベースプレイヤ 4 体と対戦した時の平均スコアである．図 1 より，それぞれの組み合わせがスコアに影響を与えることが確認できた．

表 1　強化学習における平均スコアの推移

学習回数	0	250	500	700	1000
平均スコア	2.65	2.72	2.83	2.86	2.85

表 1 は，強化学習で作成したモデルにおける，各学習回数に対する平均スコアの推移である．

4　まとめ

本研究では，大貧民における方策・価値評価関数を学習し，その情報を用いて有効な手を見つける手法を提案した．実験の結果，方策・価値評価関数の両方を利用することで，それぞれの組み合わせがスコアに影響を与えることが確認できた．また，強化学習によるクライアントの強化も見られた．今後の課題として，強化学習の手法の改善や，ネットワーク構成の改良，対戦回数の増加などが挙げられる．

参考文献

[1] 内田 順平，穴田 一, “ニューラルネットワークによる大貧民のカード提出モデル構築”, 第 36 回ファジィシステムシンポジウム講演論文集, 2020.

[2] 電気通信大学, “UECda コンピュータ大貧民大会”, https://flute.u-shizuoka-ken.ac.jp/daihinmin/2023/document_rules.html, 2026 年 2 月 2 日閲覧.